UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN
FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA
COORDINACIÓN DE TECNOLOGÍAS DE INFORMACIÓN

ACTIVIDAD PRÁCTICA · UNIDAD 4

LABORATORIO ETL: DEL ARCHIVO CRUDO AL DATA MART

Arquitectura de Capas, Normalización Canónica, Mesa de Rechazos, Idempotencia (UPSERT), Conciliación y Analítica de Negocio en MySQL 8.0

Unidad de Aprendizaje: Inteligencia de Negocios (BI)
Empresa Asignada: Casa&Estilo; (Retail E-commerce)
Entorno Tecnológico: MySQL Server 8.0 · Docker · Workbench

Miembro del Equipo 8	Matrícula	Carrera / Plan
Sergio Jaziel Butzmann Martinez	2163239	Ingeniería en Tecnologías de Software (ITS)
Arely Carrillo Sustaita	2226630	Ingeniería en Tecnologías de Software (ITS)
Rafael Jesús Collazo Hernández	2169304	Ingeniería en Tecnologías de Software (ITS)

Semestre: Agosto - Diciembre 2026
San Nicolás de los Garza, Nuevo León, México

1. Propósito, Escenario y Entregables del Laboratorio

El presente laboratorio técnico tiene como propósito simular un escenario real de ingeniería de datos para la empresa de retail y comercio electrónico **Casa&Estilo;**. La organización recibe flujos periódicos de datos provenientes de diferentes canales transaccionales (archivos planos clientes.csv, transacciones pedidos.sql y un catálogo de entidades federativas catalogo_estados.csv). Los datos crudos presentan defectos e inconsistencias deliberadas: registros duplicados, fechas con formatos mixtos, importes nulos o negativos, clientes inexistentes y alias de estados no homologados.

Regla Fundamental de Calidad: Bajo ninguna circunstancia se deben corregir manualmente los archivos de origen. Todo el saneamiento, tipado y validación debe ser ejecutado de forma programática, automatizada y reproducible a través de un pipeline SQL implementado en **MySQL Server 8.0**.

Entregables Oficiales de la Práctica:

1. ***Script SQL Maestro y Scripts Modulares:*** *Código DDL/DML determinista e idempotente.*
2. ***Reporte de Diagnóstico y Cuarentena:*** *Evidencia de volumetrías, perfilado y las 8 transacciones rechazadas.*
3. ***Prueba de Idempotencia:*** *Demostración matemática del mecanismo UPSERT sin duplicación de hechos.*
4. ***Conciliación Cuantitativa y Financiera:*** *Registro formal en etl_auditoria (Balance de Masa = 0).*
5. ***Consulta Final de Indicadores de Negocio:*** *Reporte de ventas netas y órdenes entregadas por estado y fecha.*
6. ***Reflexión Crítica:*** *Justificación técnica sobre decisiones de limpieza, detección de pedidos tardíos y devoluciones.*

2. Arquitectura de Datos por Capas (Multi-Tier Pipeline)

Capa	Tablas Físicas	Rol y Principio de Gobierno

Raw Zone (Aterrizaje)	`raw_clientes`
	`raw_pedidos`
	`catalogo_estados`
		Inmutable y de sólo inserción. Almacena la verdad fáctica recibida tal como ingresó de las fuentes. Permite reprocesar el pipeline ante cualquier cambio de regla.

Staging (Refinamiento)	`stg_clientes`
	`stg_pedidos`
	`stg_pedidos_limpios`
		Transformación y tipado fuerte. Convierte textos a DATE y DECIMAL, deduplica clientes mediante ROW_NUMBER() y homologa claves estatales canónicas.

Cuarentena (Error Mart)	`pedidos_rechazados`	**Mesa de rechazos auditable.** Aísla registros con violaciones de reglas de calidad sin interrumpir la ejecución ni borrar datos.

Data Mart (Esquema Estrella)	`dim_estado`
	`dim_cliente`
	`fact_ordenes`
		Modelo dimensional analítico. Carga incremental con INSERT ... ON DUPLICATE KEY UPDATE (UPSERT) garantizando idempotencia estricta.

Gobierno (Auditoría)	`observaciones_perfilado` `etl_auditoria`	**Balance de masa y conciliación.** Cuadra matemáticamente: *Total Raw* = *Total Limpios* + *Total Rechazados* (Discrepancia = 0).

3. Paso 1: Perfilado de Datos y Diagnóstico de Calidad

El diagnóstico de calidad ejecutado por el script 01_perfilado_datos.sql detectó 11 observaciones críticas, las cuales fueron guardadas formalmente en la tabla observaciones_perfilado:

Tabla Origen	Métrica / Regla	Afectados	Severidad	Detalle del Hallazgo
raw_clientes	VOLUMETRIA_TOTAL	21	INFO	Total de registros ingresados desde clientes.csv
raw_pedidos	VOLUMETRIA_TOTAL	32	INFO	Total de transacciones ingresadas desde pedidos.sql
catalogo_estados	VOLUMETRIA_TOTAL	10	INFO	Entidades federativas canónicas registradas
raw_clientes	DUPLICADOS_ID_CLIENTE	1	ALTA	Cliente CLI-005 repetido con estados distintos (Jalisco / JAL)
raw_pedidos	DUPLICADOS_ID_PEDIDO	2	ALTA	Transacciones duplicadas en clave natural: PED-1001 y PED-1010
raw_clientes	ESTADOS_NO_ESTANDARIZADOS	13	MEDIA	Uso de alias ('N.L.', 'D.F.', 'Nuevo Leon'), vacíos y no identificados
raw_pedidos	ESTADOS_ENVIO_NO_CANONICOS	11	MEDIA	Estados de envío con alias tipográficos o 'ESTADO_INEXISTENTE'
raw_clientes	FECHAS_CLIENTE_NO_ISO	7	MEDIA	Formatos DD/MM/AAAA ('14/02/2026') y cliente CLI-020 con fecha vacía
raw_pedidos	FECHAS_PEDIDO_INVALIDAS	7	ALTA	Formatos DD/MM/AAAA, fecha vacía (PED-1024) y cadena 'FECHA_ROTA' (PED-1025)
raw_pedidos	MONTOS_NO_POSITIVOS	2	ALTA	Importe negativo '-$350.00' (PED-1021) e importe cero '$0.00' (PED-1022)
raw_pedidos	CLIENTES_HUERFANOS	1	ALTA	Pedido PED-1023 referencia al cliente inexistente CLI-999

4. Pasos 2 y 3: Staging, Inmutabilidad y Normalización

Fundamento de Inmutabilidad de la Capa Raw: Modificar los datos en la zona de aterrizaje cruda destruiría la trazabilidad legal y forense de las transacciones recibidas e impediría reprocesar el pipeline ante ajustes en las reglas comerciales. Por ello, la capa stg_* actúa como el laboratorio de estandarización sin alterar el origen.

Mapeo y Normalización Geográfica: Se cruzaron los textos libres contra el catálogo de entidades oficiales mediante la búsqueda por nombre oficial, clave directa o lista de alias: FIND_IN_SET(TRIM(estado), REPLACE(ce.alias, ', ', ',')) > 0. De este modo, variantes como *'Nuevo Leon'*, *'N.L.'* y *'NL.'* convergen a la clave canónica única **'NL'**; *'D.F.'* y *'Distrito Federal'* a **'CDMX'**; y *'Jal.'* a **'JAL'**. A los clientes sin estado asignado se les imputó el valor centinela **'NE'** (*No Especificado*).

Parsing Robusto de Fechas: Para evitar fallos por modo estricto en MySQL (Error 1411), se implementó una estructura condicional con expresiones regulares (CASE WHEN fecha REGEXP ...) que reconoce tanto el estándar ISO (%Y-%m-%d) como el formato tradicional (%d/%m/%Y), convirtiéndolos al tipo nativo DATE y asignando NULL seguro a cadenas corruptas o vacías para su posterior cuarentena.

5. Paso 4: Validación y Aislamiento de Rechazos (Cuarentena)

Para proteger la integridad referencial y financiera del Data Mart sin perder visibilidad operativa de los errores, se creó la tabla de cuarentena pedidos_rechazados. De las 32 órdenes crudas, exactamente **8 transacciones fueron descalificadas** con documentación de causa raíz, y **24 transacciones limpias** pasaron a stg_pedidos_limpios:

ID Rechazo	Fila Raw	ID Pedido	ID Cliente	Monto Raw	Motivo de Rechazo	Detalle Técnico del Error
1	27	PED-1001	CLI-001	$1,250.00	**ID_PEDIDO_DUPLICADO**	Segunda aparición en lote; ya existe una transacción previa con esta clave.
2	28	PED-1010	CLI-010	$2,650.00	**ID_PEDIDO_DUPLICADO**	Transacción repetida en lote crudo.
3	23	PED-1023	CLI-999	$1,500.00	**CLIENTE_INEXISTENTE**	Cliente huérfano; no existe en la dimensión de clientes.
4	24	PED-1024	CLI-007	$1,200.00	**FECHA_INVALIDA**	Cadena de fecha vacía ([VACIO]).
5	25	PED-1025	CLI-008	$980.00	**FECHA_INVALIDA**	Valor corrupto no convertible a DATE ('FECHA_ROTA').
6	21	PED-1021	CLI-002	-$350.00	**IMPORTE_NO_POSITIVO**	Importe negativo que distorsiona la facturación de venta.
7	22	PED-1022	CLI-004	$0.00	**IMPORTE_NO_POSITIVO**	Importe en cero sin intercambio económico.
8	26	PED-1026	CLI-009	$1,400.00	**ESTADO_NO_RECONOCIDO**	Destino 'ESTADO_INEXISTENTE' sin coincidencia en catálogo estatal.

6. Paso 5: Carga Incremental al Data Mart y Demostración de Idempotencia

Fundamento de Idempotencia: Un pipeline de datos es idempotente si su ejecución repetida sobre el mismo conjunto de datos produce exactamente el mismo estado final en el destino: $f(f(x)) = f(x)$. Esto se logra definiendo **claves primarias naturales estables** (id_cliente en la dimensión y id_pedido en los hechos) e implementando la instrucción INSERT ... ON DUPLICATE KEY UPDATE (UPSERT). Si el motor detecta que la clave ya existe en el índice primario B-Tree, ejecuta una actualización en sitio en lugar de crear un registro duplicado.

Concepto de Evaluación	Corrida Inicial (1)	Re-ejecución Idéntica (2)	Diferencial (Δ)	Veredicto Técnico
Filas en fact_ordenes	24 registros	24 registros	0 filas	**IDEMPOTENTE (ÉXITO)**
Monto Total Facturado	$39,210.50	$39,210.50	$0.00	**INTEGRO (SIN DESVÍO)**
Filas en dim_cliente	20 clientes	20 clientes	0 filas	**ESTABLE**

7. Paso 6: Conciliación Cuantitativa y Balance de Masa

El principio de **balance de masa** garantiza que no existe pérdida ni creación inexplicable de registros a lo largo del flujo ETL: *Total Recibido (Raw) = Aceptados Únicos (Staging) + Rechazados (Cuarentena)*. Dicha conciliación se registró automáticamente en la tabla etl_auditoria:

Métrica Cuantitativa	Valor	Métrica Financiera	Valor Monetario
Total Recibido en raw_pedidos	32 filas	Monto Bruto Total Recibido	$47,840.50
Total Aceptado en stg_pedidos_limpios	24 filas	Monto Descartado en Cuarentena	$8,630.00
Total Aislado en pedidos_rechazados	8 filas	Monto Válido en Staging Limpio	$39,210.50
Total Justificado (24 + 8)	32 filas	Monto Persistido en fact_ordenes	$39,210.50
Discrepancia Matemática	**0 filas**	**Desvío Financiero Staging vs Hechos**	**$0.00**
Balance de Masa Cuadrado	**SI (PERFECTO)**	**Estatus Global de Auditoría**	**EXITOSO**

¿Por qué el total bruto difiere del total válido?
El monto bruto ($47,840.50) representa el tráfico transaccional crudo que incluye anomalías económicas (importes negativos de -$350.00, órdenes de $0.00, transacciones a clientes inexistentes de $1,500.00, órdenes sin fecha válida de $2,180.00 y compras duplicadas por reintentos de red de $3,900.00). El total válido consolidado ($39,210.50) refleja la **verdad transaccional gobernada** apta para la toma de decisiones ejecutivas.

8. Paso 7: Indicadores Analíticos de Negocio

Supuesto Metodológico del Laboratorio: Para fines analíticos de este ejercicio, la métrica **Ventas Netas** se define estrictamente como la suma de importes de las órdenes en estatus 'Entregado'. No se modelaron deducciones fiscales (IVA), fletes ni notas de crédito por devoluciones.
De las 24 órdenes válidas, **21 fueron entregadas** ($35,810.50). Las 3 órdenes restantes corresponden a compras en proceso (1 en tránsito por $950.00, 1 pendiente por $650.00 y 1 cancelada por $1,800.00).

Clave	Entidad Federativa	Pedidos Entregados	Ventas Netas	% Participación	Ticket Promedio
YUC	Yucatán	3	$6,330.00	17.68%	$2,110.00
PUE	Puebla	3	$6,100.00	17.03%	$2,033.33
QRO	Querétaro	3	$4,400.00	12.29%	$1,466.67
JAL	Jalisco	2	$3,950.00	11.03%	$1,975.00
CDMX	Ciudad de México	2	$3,550.00	9.91%	$1,775.00
VER	Veracruz	1	$3,400.00	9.49%	$3,400.00
COAH	Coahuila	2	$2,810.00	7.85%	$1,405.00
NL	Nuevo León	2	$2,090.50	5.84%	$1,045.25
GTO	Guanajuato	2	$2,080.00	5.81%	$1,040.00
TAM	Tamaulipas	1	$1,100.00	3.07%	$1,100.00
TOTAL	**Consolidado General**	**21 órdenes**	**$35,810.50**	**100.00%**	**$1,705.26**

9. Respuestas Argumentadas a las Preguntas de Reflexión (Parte I)

Pregunta 1: ¿Qué ocurre si un cliente tiene estado vacío? ¿Se rechaza el cliente o se agrupa como no identificado?

Decisión de Diseño Adoptada: Se agrupa como no identificado bajo la clave centinela 'NE' (*No Especificado*) en dim_cliente.

Fundamentación Técnica: En comercio electrónico, un usuario suele registrarse proporcionando únicamente nombre y correo electrónico, completando su domicilio fiscal o de entrega al realizar una compra posterior. Si el pipeline rechazara al cliente en la ingesta, cualquier orden futura generada por este usuario provocaría un fallo de integridad referencial (cliente inexistente / huérfano). Conforme a las mejores prácticas dimensionales de Ralph Kimball, la creación de registros centinela permite mantener intacto el árbol relacional, al tiempo que expone a los clientes incompletos para que el equipo de CRM detone campañas de actualización.

Diferencia con el Pedido: Si un pedido reporta un estado de destino vacío o desconocido, la orden **sí debe rechazarse**, ya que el centro de distribución no puede despachar físicamente un paquete sin destino geográfico válido.

Pregunta 2: ¿Cómo detectarías pedidos que llegaron tarde?

Diagnóstico y Propuesta de Extensión: El modelo actual únicamente captura fecha_pedido, lo cual impide medir la puntualidad de despacho. Para monitorear el cumplimiento de los acuerdos de nivel de servicio (SLA), se deben incorporar dos campos temporales en el sistema origen y en fact_ordenes:

• fecha_prometida_entrega DATE: Plazo límite pactado con el cliente al momento de la compra.

• fecha_entrega_real DATE: Marca de tiempo reportada por la empresa de paquetería al entregar el paquete.

Lógica de Detección en SQL: La condición DATEDIFF(fecha_entrega_real, fecha_prometida_entrega) > 0 clasifica la orden como tardía. A partir de esto se construye el indicador clave **OTIF (On-Time In-Full)**, permitiendo identificar qué transportistas o zonas presentan mayores cuellos de botella logísticos.

Matriz Sintética de Decisiones de Limpieza y Calidad

Defecto Detectado	Capa de Tratamiento	Estrategia Técnica	Justificación de Negocio
Alias estatales ('N.L.', 'D.F.')	Staging	Cruce con catalogo_estados	Unifica segmentación geográfica sin perder clientes.
Fechas heterogéneas (DD/MM/AAAA)	Staging	STR_TO_DATE condicional con REGEXP	Permite tipado nativo DATE sin error 1411 en strict mode.
Montos <= 0 o negativos	Cuarentena	Aislamiento en pedidos_rechazados	Protege los ingresos y balances contables del Data Mart.
Transacciones duplicadas	Cuarentena / Mart	ROW_NUMBER() y UPSERT estable	Elimina sobreestimación de ventas y asegura idempotencia.

10. Respuestas a Reflexión (Parte II), Entorno Docker y Conclusión

Pregunta 3: ¿Cómo modificarías el proceso para admitir devoluciones?

Estrategia de Integración ETL y Modelado Dimensional:

1. **Ingesta de Nueva Fuente:** Recibir un archivo complementario devoluciones.csv con campos id_devolucion, id_pedido, fecha_devolucion, importe_devuelto y motivo_id.
2. **Validaciones en Staging:** Verificar integridad referencial (que el id_pedido exista en fact_ordenes y esté en estatus 'Entregado'), coherencia temporal (fecha_devolucion >= fecha_pedido) y consistencia económica (importe_devuelto <= importe_pedido_original).
3. **Modelado Dimensional Recomendado:** Implementar una tabla de hechos dedicada **fact_devoluciones** vinculada a una dimensión dim_motivo_devolucion. Esto permite reflejar contablemente el impacto del reembolso en el periodo exacto en que ocurrió (sin alterar la foto histórica de la venta original) y recalcular las **Ventas Netas Reales** como:

Ventas Netas Reales = ∑ Ventas Entregadas - ∑ Importe Devoluciones

11. Reproducibilidad Técnica y Entorno Docker

Para garantizar reproducibilidad absoluta sin requerir instalación de dependencias en el sistema anfitrión (cumpliendo con la regla de gobernanza Docker del proyecto), el pipeline se ejecuta mediante el contenedor oficial **MySQL 8.0** configurado en docker-compose.yml y validado en el workflow de GitHub Actions [.github/workflows/ci.yml].

Para ejecutar el pipeline automatizado de inicio a fin en una sola instrucción:

chmod +x unidad_4/ejecutar_laboratorio_docker.sh && ./unidad_4/ejecutar_laboratorio_docker.sh

12. Conclusión Ejecutiva del Equipo 8

El desarrollo del Laboratorio ETL para Casa&Estilo; demostró que la construcción de un Data Mart no se limita a escribir sentencias SQL básicas, sino que exige una rigurosa arquitectura de ingeniería de datos: inmutabilidad en la capa de ingesta, normalización determinista en staging, aislamiento transparente de errores en mesas de rechazos, garantías de idempotencia para prevenir duplicidades contables y conciliaciones matemáticas de balance de masa. Estas prácticas aseguran que las decisiones estratégicas de la organización descansen sobre una base gobernada, precisa y reproducible.

Sergio Jaziel Butzmann Martinez
Matrícula: 2163239
Ingeniería en Tecnologías de Software

Arely Carrillo Sustaita
Matrícula: 2226630
Ingeniería en Tecnologías de Software

Rafael Jesús Collazo Hernández
Matrícula: 2169304
Ingeniería en Tecnologías de Software